

Wrocław University
of Science and Technology



Department
of Artificial
Intelligence

Analiza sprzeczności wypowiedzi polityków a konsensus naukowy

Jak działa pipeline?

GRUPA PROJEKTOWA

Michał Kałuski
Lead badawczy

Filip Puszko
Inżynier danych

Damian Kwolek
Inżynier pipelinu

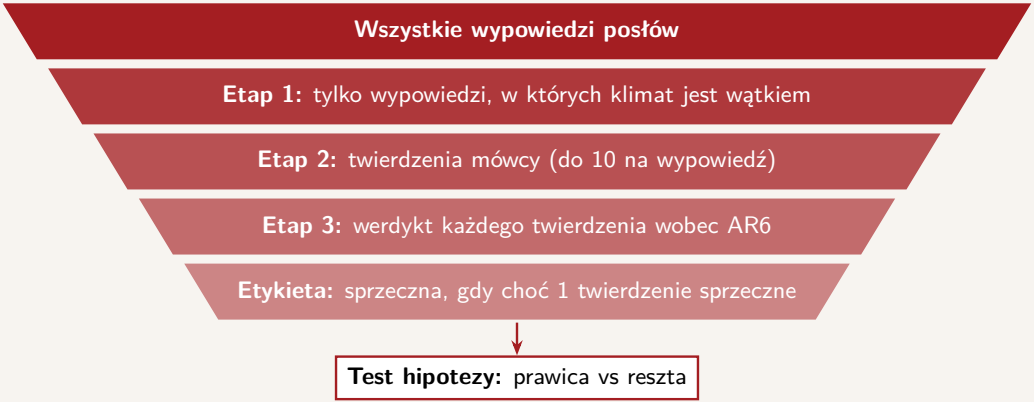
Mateusz Rzeźnikiewicz
Inżynier analityk

Plan prezentacji

Wrocław University of Science and Technology

1	**Dane i populacja**	Skąd biorą się wypowiedzi i kto wchodzi do badania?
2	**Wątek klimatyczny**	Etap 1: które wypowiedzi w ogóle dotyczą klimatu?
3	**Twierdzenia mówcy**	Etap 2: co dokładnie mówca twierdzi o świecie?
4	**Werdykt wobec AR6**	Etap 3: RAG i PaperQA2, reguły codebooka.
5	**Gold standard i test**	Jakość etykiet, test hipotezy, korekta błędu klasyfikatora.
6	**Odporność i raport**	Testy odporności i co trafia do raportu.

Pipeline jako lejek



Każdy etap wykonuje lokalny model Gemma 4 12B według promptu z codebooka.

1. Dane: skąd je bierzemy?

Wrocław University of Science and Technology

Wszystkie dane pochodzą z publicznego API Sejmu RP: **api.sejm.gov.pl**.

Stenogramy

Treść każdej wypowiedzi z posiedzeń plenarnych, z mówcą i datą.

Posłowie

Lista posłów X kadencji wraz z identyfikatorem, imieniem i nazwiskiem.

Głosowania

Listy głosujących posłów z każdego dnia obrad wraz z ich klubem.

1. Dane: kto wchodzi do populacji?

Wrocław University of Science and Technology

Kryteria doboru wypowiedzi

1. **Okres:** 13.11.2023 - 15.09.2026, czyli od początku X kadencji Sejmu do daty granicznej z hipotezy.
2. **Miejsce:** posiedzenia plenarne całej izby, a nie posiedzenia komisji czy zespołów poselskich.
3. **Mówca:** poseł (także minister będący posłem), ale bez gości spoza Sejmu i prowadzącego obrady.
4. **Treść:** wypowiedź merytoryczna, czyli minimum 40 słów, bo krótkie wtrącenia nie niosą twierdzeń do oceny.

43 991

wypowiedzi w populacji

2. Czy klimat jest wątkiem wypowiedzi?

Wrocław University of Science and Technology

Reguła z codebooka

Słowo **„klimat”** pada w Sejmie w wielu kontekstach. Dlatego model nie szuka samego słowa, lecz ocenia, czy mówca coś twierdzi o klimacie lub polityce klimatycznej, czy jest on tylko tłem innego tematu.

- **Wątek (1):** skutki lub przyczyny zmiany klimatu, ETS, Zielony Ład, OZE jako sposób ograniczania emisji, negowanie zmiany klimatu.
- **Tło (0):** „klimat inwestycyjny” (inne znaczenie), „w dobie zmian klimatu”, smog, ceny energii bez wzmianki o emisjach.

Wejście i wyjście

Wejście: cała wypowiedź posła.

Wyjście: odpowiedź jako JSON.

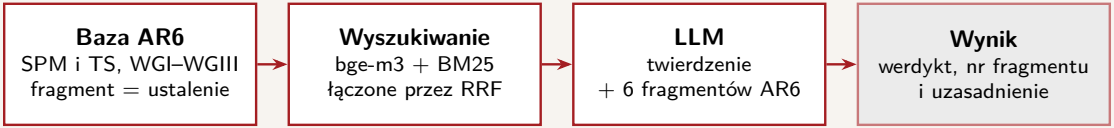
```
{
  "klimat": 1,
  "fragment": "Zmiana klimatu
    powoduje, że opady są
    bardzo intensywne..."
}
```

Co nazywamy twierdzeniem?

Model wypisuje z każdej wypowiedzi tylko twierdzenia, czyli zdania mówcy o stanie świata, które raport AR6 mógłby potwierdzić albo obalić.

- **Bierzemy:** przyczyny i skutki zmiany klimatu, stan nauki o klimacie, dane o emisjach.
- **Pomijamy:** epitety, postulaty, koszty i tempo polityki, przepisy, twierdzenia o osobach.
- **Ironia i polemika:** gdy mówca wyśmiewa cudzą tezę, zapisujemy jej zaprzeczenie.

4. Werdykt wobec AR6 (RAG)



Możliwe są trzy werdykty:

1. `sprzeczne`: twierdzenie przeczy ustaleniu z fragmentu AR6,
2. `zgodne`: twierdzenie odpowiada ustaleniu z fragmentu AR6,
3. `brak_podstaw`: fragmenty AR6 tego nie rozstrzygają.

Bez wskazanego fragmentu AR6 werdykt zawsze brzmi `brak_podstaw`, niezależnie od wiedzy własnej modelu.

5. Jak model ocenia trudne przypadki?

Wrocław University of Science and Technology

Cytat	Wyjaśnienie	Werdykt
„Za 10 lat zmiana klimatu doprowadzi do końca świata."	Wyolbrzymianie przeczy AR6 tak samo jak umniejszanie.	`sprzeczne`
„Unia Europejska odpowiada za 7% światowych emisji CO_2."	AR6 podaje dane dla Europy, a nie dla Unii.	`brak_podstaw`
„System ETS podnosi ceny prądu w Polsce."	Ceny i koszty to ekonomia, a nie nauka o klimacie.	`brak_podstaw`
„Redukcja emisji w Polsce nic nie zmieni."	Ocieplenie zależy od łącznej emisji CO_2 świata.	`sprzeczne`

6. Drugi weryfikator: PaperQA2

Wrocław University of Science and Technology

PaperQA2 to otwarty system RAG do pytań o literaturę naukową. Dostaje te same dokumenty co nasz RAG (SPM i TS z WGI - WGIII, czyli 6 PDF-ów) i ten sam model.

1. **Dzieli i wyszukuje**
   kawałki stałej długości pasujące do twierdzenia
2. **Streszcza**
   każdy kawałek osobno, pod kątem twierdzenia
3. **Odpowiada**
   werdykt z cytowaniami, według reguł codebooka

Po co dwa weryfikatory? Jeśli oba dają podobne werdykty, wynik nie zależy od sposobu wyszukiwania.

7. Gold standard: ile warte są etykiety modelu?

Wrocław University of Science and Technology

Losowanie warstwowe

W każdej grupie losujemy do ręcznej oceny:

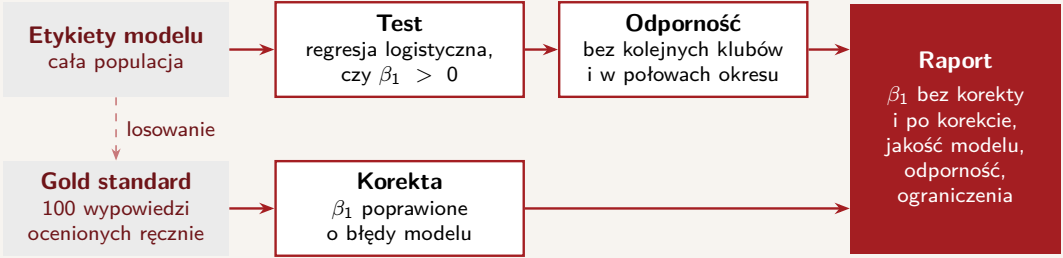
- 20 wypowiedzi **sprzecznych** wg modelu,
- 15 **tematycznych, niesprzecznych**,
- 15 **nietematycznych**.

Sprzecznych jest mało, więc bierzemy ich więcej. Wagi wyrównują to w wynikach.

Anotacja na ślepo

- Anotator widzi tylko tekst, bez mówcy, klubu i etykiety modelu.
- Ocenia, czy wypowiedź jest o klimacie i czy jest sprzeczna z AR6.

8. Od etykiet do wyniku



9. Testy odporności

Jak działają?

Sprawdzamy, jak mocno wynik zależy od warunków, w których mierzymy zjawisko, a dokładnie od tego, kto tworzy prawicę i kiedy padły wypowiedzi. Liczymy ten sam test jeszcze kilka razy. Za każdym razem bez jednego klubu prawicy (np. bez PiS albo bez Konfederacji), a potem osobno dla pierwszej i drugiej połowy kadencji. Jeśli wynik się nie zmienia, warunki mają na niego słaby wpływ. Jeśli się zmienia, wiemy, który z nich go kształtuje.

Wynik jest odporny, gdy w każdym wariancie:

- różnica między prawicą a resztą idzie w tę samą stronę co w wyniku głównym,
- różnica jest podobnie duża: od połowy do dwukrotności wyniku głównego.

10. Raport: co zawiera?

Wrocław University of Science and Technology

1. **Wynik główny:** jak bardzo prawica różni się od reszty, z przedziałem ufności, przed korektą błędów modelu i po niej.
2. **Liczby wypowiedzi:** ile wypowiedzi o klimacie ma każda grupa.
3. **Jakość modelu:** jak często model trafia, porównany z ręczną oceną oraz zgodność dwóch anotatorów.
4. **Odporność:** wynik dla każdego wariantu z testów odporności.
5. **Ograniczenia:** co może zaburzać wynik.

11. Raport: możliwe werdykty

Wrocław University of Science and Technology

Werdykt	Co oznacza?
Hipoteza potwierdzona	Po korekcie prawica ma wyraźnie więcej wypowiedzi sprzecznych.
Hipoteza niepotwierdzona	Takiej wyraźnej różnicy nie widać.
Brak możliwości pomiaru	Wypowiedzi sprzecznych jest za mało, żeby cokolwiek stwierdzić.

Każdy z tych werdyktów to pełnoprawny wynik badania.



Wrocław University
of Science and Technology



Department
of Artificial
Intelligence

Dziękujemy za uwagę

Pytania?